

## 第十章：图像识别

---

中国科学技术大学  
电子工程与信息科学系



# 图象识别

---

## □ 简单形状检测

- 霍夫变换 (Hough Transform)

- 倒角距离变换 (Chamfer Distance Transform)

## □ 图像分类

## □ 图像检索

# 霍夫变换 (Hough Transform)


## □ 应用场景：直线拟合



如何从**边缘检测**的结果得到直线拟合的结果？

## □ 直线拟合的难点

- 边缘检测点杂乱且多余
- 不同的检测点属于不同的直线
- 部分线段可能漏检
- 边缘检测点上存在噪声





# 霍夫变换 (Hough Transform)

---

## □ 基本思想：基于投票的机制

- 视待检测形状为一个模型(model)
- 让每个样本（像素）对所有与其兼容的模型进行投票
- 假设噪声样本不会偏好任何单个模型
- 即使有部分样别缺失，当有足够样本保留时，仍可将目标模型（形状）检测出来


# 霍夫变换原理：以直线检测为例

## □ Hough Transform

- 图像空间与参数空间之间的一种变换

## □ Hough参数空间


- 在图像空间中的一条直线，对应于Hough参数空间中的一个点




# 霍夫变换：直线检测

- 参数空间的一条直线对应图像空间的一个点
- 图像空间中同一条直线上的任意两个点，在参数空间中对应于两条相交的直线
  - 即在图像空间共线的 $n$ 个点，对应于参数空间 $n$ 条共点 $(p_0, q_0)$ 的直线

图像空间



Hough参数空间



# 霍夫变换：直线检测


## □ 具体方法

- 将参数空间离散成一个2-D的累加数组  $A(p, q)$

$$p \in [p_{\min}, p_{\max}]$$

$$q \in [q_{\min}, q_{\max}]$$

- $A(p, q) = A(p, q) + 1$   
 $A(p, q)$ : 共线点数  
 $(p, q)$ : 直线方程参数



## □ 潜在的问题

- $p_{\min}$  和  $q_{\min}$  可能为无穷小,  $p_{\max}$  和  $q_{\max}$  可能为无穷大, 难以对其进行离散化

# 霍夫变换：直线检测的改进形式

## □ 直线的极坐标方程




$$\lambda = x \cos \theta + y \sin \theta$$

- 参数 $\lambda$ 和 $\theta$ 唯一确定一条直线

## □ X-Y平面的一个点对应参数空间的一条正弦曲线

- $\lambda = x_0 \cos \theta + y_0 \sin \theta \leftrightarrow \lambda = A \sin(\theta + \alpha)$

$$\text{其中 } \alpha = \tan^{-1} \left( \frac{x_0}{y_0} \right), A = \sqrt{x_0^2 + y_0^2}$$








# 霍夫变换：其他形状的检测

- 对于满足显式解析式  $f(x, c) = 0$  形式的各类曲线，霍夫变换可以将其检测出来，并把曲线上的点完整地连接起来
- 示例：以圆周检测为例
  - 圆周方程：  $(x - a)^2 + (y - b)^2 = r^2$
  - 三个参数  $a$ 、 $b$ 、 $r$ ，所以需要在参数空间中建立3-D累加数组，其中的元素可以记为  $A(a, b, r)$

# 霍夫变换：圆周检测

## □ 示例



图(a)为256x256，灰度256级，叠加随机噪声；

图(b)为求梯度(Sobel算子)取阈值后的结果；


图(c)哈夫变换累加器图；

图(d)为检测出的圆周附加在原图上的效果


# 霍夫变换：圆周检测

## □ 利用梯度降维

- 使累加数组的维度减少一维
- 圆周——圆周对偶性



$$(a - x)^2 + (b - y)^2 = r^2$$



# 霍夫变换：圆周检测

## □ 利用梯度降维

- 圆周圆心在圆周边缘点的梯度方向上


$$a = x - r \sin \theta$$

$$b = y + r \cos \theta$$


1个3-D累加器数组



2个2-D累加器数组



(a)



(b)

利用梯度与否 2 种情况下的累加数组示意



# 广义霍夫变换

---

- 广义Hough变换将一般的模板匹配与**Hough变换**相结合
- 先对模板与图象上的物点作**坐标变换**，然后**求相关**
- 并用类似Hough变换检测物体的表决方法来确定匹配点

# 广义霍夫变换原理

## □ 给定模板的一组点集

- $B = \{(x_i, y_i), i = 1, 2, \dots, m\}$

## □ $P(x_0, y_0)$ 为一参考点，常把 $P$ 取为 $B$ 的中心点。


- 从而将  $B$  表达为  $B = \{(dx_i, dy_i), i = 1, 2, \dots, m\}$

$$H(B, P)$$

$$\{(dx_i, dy_i), i = 1, 2, \dots, n\}$$



$$dx_i = x_0 - x_i = -(x_i - x_0)$$

$$dy_i = y_0 - y_i = -(y_i - y_0)$$



# 广义霍夫变换原理

- 检测时，将待测图象，记为点集 $E$ ：
  - $E = \{(u_j, v_j), j = 1, 2, \dots, n\}$
- 将待检测点集与变换后的模板 $B$ 做相关运算
  - $\forall i, j$ , 计算 $\mathbf{m}(i, j) = (dx_i + u_j, dy_i + v_j)$ ,
  - 如果有很多点 $\mathbf{m}(i, j)$ 都对应同一个坐标点，则该点为与 $B$ 相匹配的形狀的中心位置



# 广义霍夫变换原理

- 在所需检测的曲线或目标轮廓没有或不易用解析式表达时，可以利用**表格**来建立**曲线或轮廓点**与**参考点**间的关系，从而可继续利用哈夫变换进行检测

建立参考点与轮廓点的联系：

$$p = x + r(\theta) \cdot \cos(\phi(\theta))$$

$$q = y + r(\theta) \cdot \sin(\phi(\theta))$$




图 6.1.8 建立参考点和轮廓点的对应关系



# 广义霍夫变换原理


- 已知轮廓形状、朝向和尺度而只需检测位置信息
- 根据 $\theta, r$ 和 $\phi$  的函数关系作出参考表

梯度角 $\theta$	矢径 $r(\theta)$	矢角 $\phi(\theta)$
$\theta_1$	$r_1^1, r_1^2, \dots, r_1^{N_1}$	$\phi_1^1, \phi_1^2, \dots, \phi_1^{N_1}$
$\theta_2$	$r_2^1, r_2^2, \dots, r_2^{N_2}$	$\phi_2^1, \phi_2^2, \dots, \phi_2^{N_2}$
...	...	...
$\theta_M$	$r_M^1, r_M^2, \dots, r_M^{N_M}$	$\phi_M^1, \phi_M^2, \dots, \phi_M^{N_M}$

- 给定一个测试点 $(x', y')$  及其梯度角 $\theta'$ ，即可确定一组可能的参考点位置
  - 根据梯度角 $\theta'$ ，找到表中对应梯度角所在行的矢径和视角序列
  - 基于坐标 $(x', y')$ 和序列中每一组 $(r, \phi)$ 值，反推出形状参考点坐标
$$p' = x' + r(\theta) \cdot \cos(\phi(\theta))$$
$$q' = y' + r(\theta) \cdot \sin(\phi(\theta))$$

# 广义霍夫变换原理

轮廓点	$a$	$a'$	$b$	$b'$	$C$	$c'$	$d$	$d'$
矢径 $r(\theta)$	$\sqrt{2}/2$	$1/2$	$\sqrt{2}/2$	$1/2$	$\sqrt{2}/2$	$1/2$	$\sqrt{2}/2$	$1/2$
矢角 $\phi(\theta)$	$1\pi/4$	$2\pi/4$	$3\pi/4$	$4\pi/4$	$5\pi/4$	$6\pi/4$	$7\pi/4$	$8\pi/4$




梯度角 $\theta$	矢径 $r(\theta)$		矢角 $\phi(\theta)$	
$\theta_a = \pi/2$	$\sqrt{2}/2$	$1/2$	$\pi/4$	$2\pi/4$
$\theta_b = 2\pi/2$	$\sqrt{2}/2$	$1/2$	$3\pi/4$	$4\pi/4$
$\theta_c = 3\pi/2$	$\sqrt{2}/2$	$1/2$	$5\pi/4$	$6\pi/4$
$\theta_d = 4\pi/2$	$\sqrt{2}/2$	$1/2$	$7\pi/4$	$8\pi/4$

# 广义霍夫变换原理

- 利用正方形上的8个轮廓点判断可能参考点位置( $p', q'$ )
- 对每个 $\theta$ 有 2个  $r$  及2个  $\phi$  与之对应

$$\begin{aligned} p' &= x' + r(\theta) \cdot \cos(\phi(\theta)) \\ q' &= y' + r(\theta) \cdot \sin(\phi(\theta)) \end{aligned}$$



梯度角	轮廓点	可能参考点		轮廓点	可能参考点	
$\theta_a$	$a$	$O$	$d'$	$a'$	$b'$	$O$
$\theta_b$	$b$	$O$	$a'$	$b'$	$c'$	$O$
$\theta_c$	$c$	$O$	$b'$	$c'$	$d'$	$O$
$\theta_d$	$d$	$O$	$c'$	$d'$	$a'$	$O$

点 $O$ 出现频率最高



# 广义霍夫变换的性能

---

- ☐ 运算量较小
- ☐ 抗干扰性也较强
- ☐ 可以求出曲线的某些参数
- ☐ 可适用于不规则曲线
- ☐ 仍不具有不变性



# 完整广义霍夫变换

□ 轮廓的平移 + 轮廓放缩、旋转

□ 累加数组：

□  $A(p_{\min}: p_{\max}, q_{\min}: q_{\max}, \beta_{\min}: \beta_{\max}, S_{\min}: S_{\max})$

$$p = x + S \times r(\theta) \times \cos[\phi(\theta) + \beta]$$

$$q = y + S \times r(\theta) \times \sin[\phi(\theta) + \beta]$$

□ 累加数组的累加：  $A(p, q, \beta, S) = A(p, q, \beta, S) + 1$


# 完整广义霍夫变换

假设已知  $S = 1$ ,  $\beta = \pi/4$

## 计算示例

原梯度角 $\theta$	新梯度角 $\theta'$	矢径 $r(\theta)$	新矢角 $\phi(\theta)$
$\theta_a = \pi/2$	$\theta'_a = 3\pi/4$	$\sqrt{2}/2$ 1/2	$2\pi/4$ $3\pi/4$
$\theta_b = 2\pi/2$	$\theta'_b = 5\pi/4$	$\sqrt{2}/2$ 1/2	$4\pi/4$ $5\pi/4$
$\theta_c = 3\pi/2$	$\theta'_c = 7\pi/4$	$\sqrt{2}/2$ 1/2	$6\pi/4$ $7\pi/4$
$\theta_d = 4\pi/2$	$\theta'_d = \pi/4$	$\sqrt{2}/2$ 1/2	$8\pi/4$ $1\pi/4$

梯度角	轮廓点	可能参考点	轮廓点	可能参考点
$\theta'_a$	$a$	$O$	$d'$	$a'$ $b'$ $O$
$\theta'_b$	$b$	$O$	$a'$	$b'$ $c'$ $O$
$\theta'_c$	$c$	$O$	$b'$	$c'$ $d'$ $O$
$\theta'_d$	$d$	$O$	$c'$	$d'$ $a'$ $O$





# 目标检测

---

## ☐ 简单形状检测

- 霍夫变换 (Hough Transform)
- 倒角距离变换 (Chamfer Distance Transform)

## ☐ 图像分类

## ☐ 图像检索

# 倒角距离变换 (Chamfer Distance Transform)


## □ 从一个问题出发

- 如何从下面左图二值边缘图像中检测匹配右图所示的三角形形状？



## □ 基本思路：

- 把右图作为模板，将其中心置于左图所有可能的像素位置
- 对于每个放置位置 $x$ ，计算模板形状与测试图像边缘的匹配距离



$$D(x) = \frac{1}{|T|} \sum_{t \in T} d_I(t + x)$$

- $T$  是模板形状（像素点的集合）， $t$  为其中一个点的坐标
- $I$  是待匹配的边缘图像（像素点的集合）
- $d_I(y)$  是坐标点  $y$  到  $I$  中所有边缘点的最近点的距离

- 将最小匹配距离 所对应的位置  $x$ ，视为匹配位置



# 倒角距离变换 (Chamfer Distance Transform)

## □ 计算复杂度分析


- 假设测试图像中边缘点数量为 $M$ 、像素点数量为 $P$ ，模板中边缘点数量为 $N$ ，上述距离计算的复杂度为 $O(MNP)$
- 上面距离测度存在大量计算冗余

## □ 如何降低冗余？

- 事先计算测试图像中边缘点的距离变换
- 图  $I$  中的边缘点集合  $E$ ，像素点  $p$  的距离变换结果为：

$DF_I(p) = \min_{x \in E} \text{dist}(p, x)$ ，其中  $\text{dist}(\cdot, \cdot)$  表示距离函数，如棋盘距离

边缘图



距离变换结果

1	0	1	2	3	4	3	2
1	0	1	2	3	3	2	1
1	0	1	2	3	2	1	0
1	0	0	1	2	1	0	1
2	1	1	2	1	0	1	2
3	2	2	2	1	0	1	2
4	3	3	2	1	0	1	2
5	4	4	3	2	1	0	1

# 倒角距离变换 (Chamfer Distance Transform)

## □ 倒角距离变换:


- 基于  $DF_I$ , 对模板形状进行倒角匹配(Chamfer matching)

$$D_{chamfer}(\mathbf{x}) = \frac{1}{|T|} \sum_{t \in T} d_I(\mathbf{t} + \mathbf{x}) = \frac{1}{|T|} \sum_{t \in T} DF_I(\mathbf{t} + \mathbf{x})$$


- $T$  是模板形状 (像素点的集合)
- $I$  是待匹配的边缘图像 (像素点的集合)
- $d_I(t)$  是模板中的点  $t$  到  $I$  中边缘点的最小的距离

- 计算复杂度:  $O(MNP) \rightarrow O(NP)$


边缘图




距离变换结果



模板



倒角变换距离



(后面五列结果自行计算)

# 倒角距离变换 (Chamfer Distance Transform)

## □ 距离变换实例

- 在距离变换的结果中，每个位置的值表示这个位置到最近的边缘点（或者其他二值化的图片结构）的距离


$$DF_I(p) = \min_{x \in E} \text{dist}(p, x)$$



原图



边缘检测结果



距离变换结果



# 倒角距离变换：如何做距离变换？

## □ 1-D距离变换

■ 1-D  $L_1$  范数的距离变换是一个计算复杂度为 $O(n)$ 的算法

■ 算法步骤

1. 对图中任意位置的值进行初始化，当 $j$ 在特征 $P$ 中时初始化为0，否则初始化为 $\text{inf}$ 。将第 $j$ 个位置的值记为 $D[j]$

2. 前向过程: for  $j$  from 1 up to  $n-1$ ，更新 $D[j]$

$$D[j] = \min(D[j], D[j-1] + 1)$$

3. 后向过程: for  $j$  from  $n-2$  down to 0，更新 $D[j]$

$$D[j] = \min(D[j], D[j+1] + 1)$$

# 倒角距离变换：如何做距离变换？

## □ 2-D距离变换：算法步骤与1-D情况类似

### ■ 初始化距离矩阵


### ■ 前向过程：从上方和左方找离特征点最近的距离

$$D[i, j] = \min(D[i, j], D[i, j - 1] + 1, D[i - 1, j] + 1)$$

### ■ 后向过程：从下方和右方找离特征点最近的距离

$$D[i, j] = \min(D[i, j], D[i, j + 1] + 1, D[i + 1, j] + 1)$$

-	1
1	0
0	1
1	-



∞	∞	∞	∞
∞	0	∞	∞
∞	0	∞	∞
∞	∞	∞	∞

∞	∞	∞	∞
∞	0	1	∞
∞	0	∞	∞
∞	∞	∞	∞


∞	∞	∞	∞
∞	0	1	2
∞	0	1	2
∞	1	2	3

2	1	2	3
1	0	1	2
1	0	1	2
2	1	2	3


# 倒角距离变换：倒角匹配实例

## □ 手型匹配

边缘图的距离变换图



Chamfer Matching响应图





# 倒角距离变换 (Chamfer Distance Transform)

## □ 优点

- 对混乱背景干扰较为鲁棒
- 计算效率高

## □ 缺点

- 对缩放和旋转变换敏感
- 对形状的小的形变敏感
- 需要大量的模板形状，应应对目标形状的形变

## □ 改进方法

- 多尺度匹配
- 层级模型组织 (hierarchical model organization)



# 图像识别

---


- 简单形状检测
- 图像分类
  - 空间金字塔匹配
- 图像检索



# 面向图像分类的空间金字塔匹配

## □ 空间金字塔匹配 (Spatial Pyramid Matching)

- 基于局部视觉特征（如SIFT）和词袋模板，一副图像中的各个局部视觉特征可表达为相应的视觉单词
- 不同类别的图像，视觉单词在图像平面服从某种空间分布
- 如何表达视觉单词间的空间上下文关系？
  - ✓ 空间金字塔：在第  $l$  层，将图像平面均匀划分为  $2^l \times 2^l$  份，  $0 \leq l \leq L$



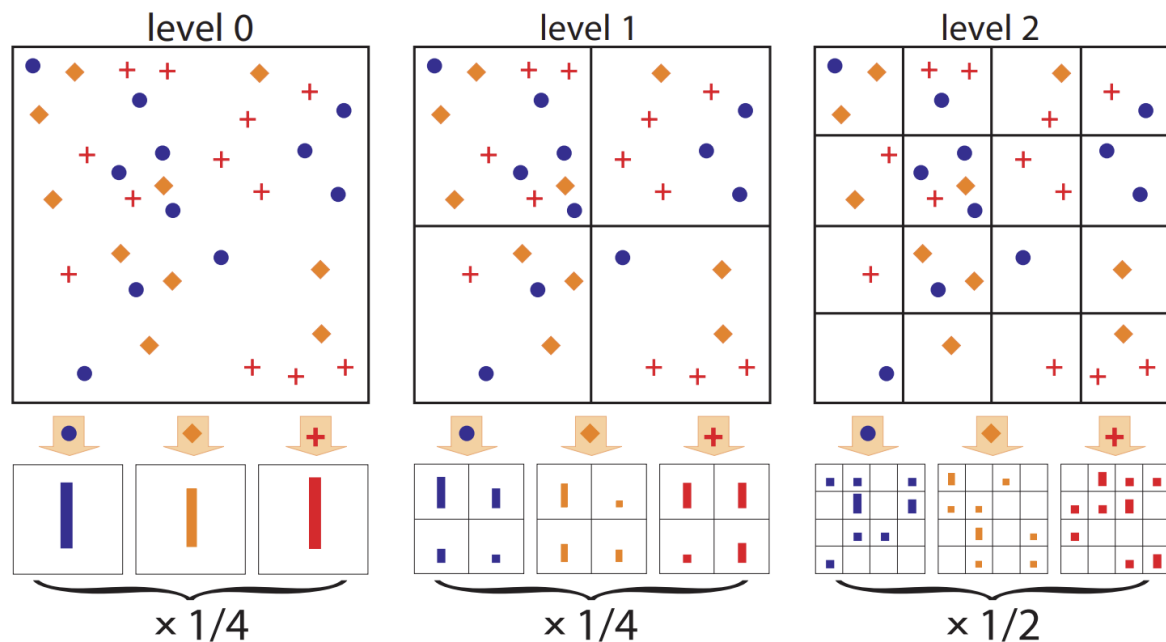
- Lazebnik S, Schmid C, Ponce J. Beyond bags of features: Spatial pyramid matching for recognizing natural scene categories. IEEE CVPR, 2006, 2: 2169-2178.

# 面向图像分类的空间金字塔匹配

## □ 视觉单词的空间金字塔表达

- 空间金字塔：在第  $l$  层，将图像平面均匀划分为  $2^l \times 2^l$  个格子区域
- 对每个划分的格子区域，将其表达为视觉单词直方图
- 在第  $l$  层，两幅图像  $X$  和  $Y$  匹配的视觉单词数量（直方图交）：

$$\mathcal{I}^l = \mathcal{I}(H_X^l, H_Y^l) = \sum_{i=1}^D \min(H_X^l(i), H_Y^l(i)). \quad (D \text{ 为格子数量})$$



# 面向图像分类的空间金字塔匹配

## □ 视觉单词的空间金字塔表达

- 对于两幅图像，第  $l$  层匹配的视觉单词 包含第  $l + 1$  层匹配的  
所有视觉单词
- 所以，相对于第  $l + 1$  层，第  $l$  层的新增匹配定义为  $I^l - I^{l+1}$ ，  
对应的权值为  $\frac{1}{2^{L-l}}$ ，反比于该层格子宽度
  - ✓ 格子宽度越大，匹配噪声越严重，越不可靠，故权值越小
- **空间金字塔匹配 (SPM)**
  - ✓ 对于两幅图像  $X$  和  $Y$ ，其  $L$  层的空间金字塔匹配核：

$$\begin{aligned}\kappa^L(X, Y) &= \mathcal{I}^L + \sum_{\ell=0}^{L-1} \frac{1}{2^{L-\ell}} (\mathcal{I}^\ell - \mathcal{I}^{\ell+1}) \\ &= \frac{1}{2^L} \mathcal{I}^0 + \sum_{\ell=1}^L \frac{1}{2^{L-\ell+1}} \mathcal{I}^\ell.\end{aligned}$$



# 图像识别

---

- 简单形状检测
- 图像分类
- 图像检索
  - 倒排索引
  - 空间验证
  - 二值哈希

# 图像检索

## □ 基于内容的图像检索




## □ 图像检索的潜在应用场景



# 图像数据库索引：正向索引

## □ 正向索引

- 基于词袋模型，每幅图像表达为一个维度为 $K$ 的矢量
- 遍历数据库图像，一一计算与查询图像的相似性得分



- 在大规模图像检索中:  $M \gg K$ 。遍历  $M$  张图像逐一计算相似性，耗时太久。

## ■ 如何改进?

- ✓ 去除向量距离计算时的计算冗余

# 图像数据库索引：倒排索引


## □ 先验条件

- 图像视觉表征向量的**稀疏性**：非零元素比例低，比如  $< 1\%$
- 只需存储向量中的非零元素  $\rightarrow$  视觉单词在词典中的索引

## □ 倒排索引的优势：高效的存储和计算

- 根据向量距离公式，**仅存储和比较向量中的非0元素**

$$D(I_q, I_m) = \sum_{i=1}^K |q_i - m_i|^p = 2 + \sum_{i|q_i \neq 0, m_i \neq 0} (|q_i - m_i|^p - q_i^p - m_i^p)$$





# 图像数据库索引：倒排索引

## □ 伪代码对比

### ■ 顺排表实现：

```
D[1 : M] = 0;
For i=1 : M
    For j = 1 : K
        D[i] += (q[j]-I[i][j]) (q[j]-I[i][j]);
    End
End
```

### ■ 倒排表实现：

```
D[1 : M] = 2;
For j = 1 : K
    if q[j] > 0
        For m = 1 : len // len为第j个链表长度
            i = list[m].imgID;
            val = list[m].val;
            D[i] -= 2 · q[j] · val;
        End
    End
End
```





# 图像数据库索引：倒排索引-示例

□ 给定查询图像的 $K$ 维 $L_1$ 归一化的特征向量为 $I_q = [0.7, 0.3, 0, \dots, 0]$

■  $I_q$  仅在第1、2维的值为非零

□ 计算 $I_q$ 和 $I_1$ 、 $I_2$ 的距离：

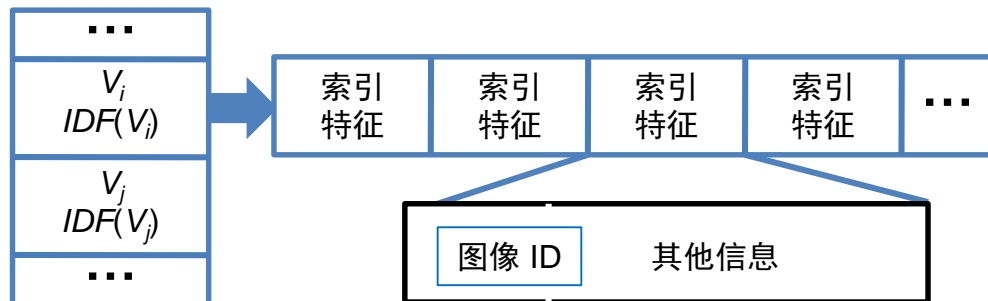
$$\begin{aligned} D(I_q, I_1) &= 2 + \sum_{i|q_i \neq 0, m_i \neq 0} (|q_i - m_i| - q_i - m_i) \\ &= 2 + (|q_2 - m_2| - q_2 - m_2) = 2 + 0.2 - 0.3 - 0.5 = 1.4 \end{aligned}$$

$$\begin{aligned} D(I_q, I_2) &= 2 + \sum_{i|q_i \neq 0, m_i \neq 0} (|q_i - m_i| - q_i - m_i) \\ &= 2 + (|q_1 - m_1| - q_1 - m_1) + (|q_2 - m_2| - q_2 - m_2) = 2 - 1.4 - 0.4 = 0.2 \end{aligned}$$

□ 计算 $I_q$ 和 $I_m$  ( $m > 2$ ) 的距离：


$$D(I_q, I_m) = 2 + \sum_{i|q_i \neq 0, m_i \neq 0} (|q_i - m_i| - q_i - m_i) = 2$$

# 图像数据库索引：倒排索引




$$D(I_q, I_m) = \sum_{i=1}^N |q_i - m_i|^p$$

$$= 2 + \sum_{i|q_i \neq 0, m_i \neq 0} (|q_i - m_i|^p - q_i^p - m_i^p)$$



特征空间

词典





# 图像分类与检索

---

## □ 图像分类

## □ 图像检索

- 倒排索引


- 空间验证

- 二值哈希

# 空间验证

## □ 动机

- 局部特征匹配时缺少对位置信息的校验
- 通过检验几何一致性去掉错误的匹配点对





红线: 几何一致的匹配点对  
蓝线: 几何不一致的匹配点对

# 视觉几何上下文表达

## □ 视觉单词以特定**空间布局**表达**视觉语义**

- 利用几何上下文提升图像匹配质量
- 有助于准确度量图像内容相关性




空间布局 vs. 视觉语义



原始匹配



噪声单词匹配



几何一致的匹配

## □ 困难和挑战

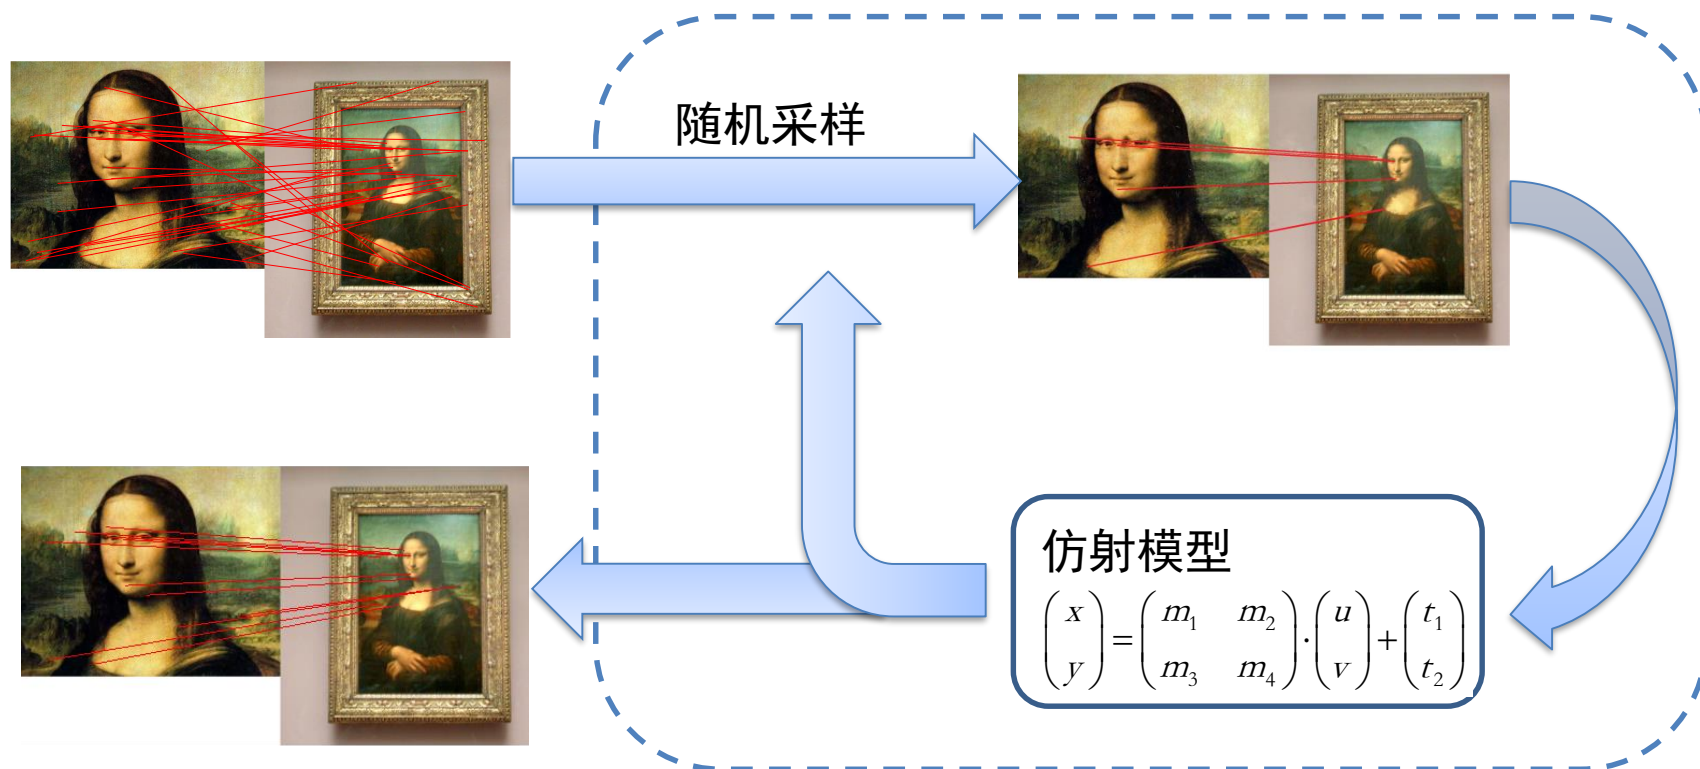
- 几何上下文**结构化**表达：便于图像匹配
- 几何上下文**快速**匹配：保证实时检索



# 几何校验(1): RANSAC

## □ RANSAC算法示例

- 通过匹配的特征点对估计图像的仿射变换



- Fischler, *et al.*, **R**ANdom **S**Ample **C**onsensus: a paradigm for model fitting with applications to image analysis and automated cartography, *Comm. of the ACM*, 24:381-395, 1981.



# 几何校验(1): RANSAC

## □ RANSAC:

- 通过正确匹配点对估计仿射模型来排除错误匹配点对
- inliers: 正确的匹配点对
- outliers: 错误的匹配点对

## □ RANdom SAmple Consensus (RANSAC)的先验条件

- 原始数据由inliers和outliers组成
- inliers的子集可以正确的估计图像间的仿射变换

## □ 通过RANSAC估计仿射变换

- 1.迭代的随机选取匹配点对当作假设的inliers
- 2.根据假设的inliers计算一个仿射模型
- 3.其他数据点根据上述的仿射模型判断是否是inliers
- 4.通过所有的inliers重新估计仿射模型
- 5.通过所有的匹配点对与模型的拟合程度计算误差

$$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} m_1 & m_2 \\ m_3 & m_4 \end{pmatrix} \cdot \begin{pmatrix} u \\ v \end{pmatrix} + \begin{pmatrix} t_1 \\ t_2 \end{pmatrix}$$

## □ 缺点: 由于随机采样点对估计模型要重复多次导致计算量大, 计算复杂度为 $O(N^3)$


# 几何校验(2): 空间编码(Spatial Coding)

## □ 核心思想: 建立空间编码矩阵

### ■ 匹配特征的相对空间位置关系

$$Xmap(i, j) = \begin{cases} 0 & \text{if } x_j > x_i \text{ right to } x_i \\ 1 & \text{if } x_j \leq x_i \text{ left to } x_i \end{cases} \quad Ymap(i, j) = \begin{cases} 0 & \text{if } y_j > y_i \text{ above } y_i \\ 1 & \text{if } y_j \leq y_i \text{ below } y_i \end{cases}$$

参考点:  $i$




$$Xmap = \begin{pmatrix} 1 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

$$Ymap = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

- Wengang Zhou, Yijuan Lu, Houqiang Li, Y. Song, and Qi Tian, "Spatial coding for large scale partial-duplicate web image search," *ACM International Conference on Multimedia (MM)*, pp.131-140, 2010.





$$\begin{aligned}
 Vx = Xq \oplus Xm &= \begin{pmatrix} 1 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 \end{pmatrix} \oplus \begin{pmatrix} 1 & 0 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 & 0 \end{pmatrix}, \\
 Vy = Yq \oplus Ym &= \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix} \oplus \begin{pmatrix} 1 & 1 & 1 & 1 & 0 \\ 0 & 1 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 1 & 1 & 1 & 1 & 1 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 \\ 1 & 1 & 1 & 1 & 0 \end{pmatrix},
 \end{aligned}$$


逐行求和

$$\begin{aligned}
 Sx &= \begin{pmatrix} 1 \\ 1 \\ 0 \\ 1 \\ 3 \end{pmatrix} \\
 Sy &= \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 4 \end{pmatrix}
 \end{aligned}$$

49

# 空间编码矩阵生成


- 在前面的例子中，每个象限只有一个部分
  - 现在将每个象限均匀的分成两个部分



# 空间编码矩阵生成

## □ 生成空间矩阵GX和GY

- 每个象限均匀的分成r个部分



- Wengang Zhou, Yijuan Lu, Houqiang Li, Y. Song, and Qi Tian, "Spatial coding for large scale partial-duplicate web image search," *ACM International Conference on Multimedia (MM)*, pp.131-140, 2010.

# 局部特征匹配的空间校验

## □ 基于空间矩阵GX和GY的验证

- 将匹配特征对的空间矩阵进行对比

$$V_x(i, j, k) = GX_q(i, j, k) \oplus GX_m(i, j, k) \quad V_x: \text{空间矩阵X中不一致的程度}$$

$$V_y(i, j, k) = GY_q(i, j, k) \oplus GY_m(i, j, k) \quad V_y: \text{空间矩阵Y中不一致的程度}$$

$k=0, \dots, r-1; i, j=1, \dots, N; N$ : 匹配特征对的数量

- 迭代地**查找**和**删除**最不一致的匹配对

$$S_x(i) = \sum_{k=0}^{r-1} \sum_{j=1}^N V_x(i, j, k)$$

$$S_y(i) = \sum_{k=0}^{r-1} \sum_{j=1}^N V_y(i, j, k)$$




$$i^* = \arg \max_i S_x(i)$$

$$j^* = \arg \max_j S_y(j)$$

找到  $i^*/j^*$ ，并  
从  $V_x$  和  $V_y$  中删除  
对应的行和列

# 局部匹配的空间校验实例

相关图像



不相关图像



空间验证前

识别的错误匹配对

空间验证后



# 图像识别

---

- 简单形状检测
- 图像分类
- 图像检索
  - 倒排索引
  - 空间验证
  - 二值哈希


# 哈希算法

## □ 大规模数据集图像检索任务的要求

- 存储开销
- 检索速度

## □ 二值哈希算法

- 减小了存储开销加快了检索速度







# 汉明距离计算-示例

- 给定两个8-bit的变量 $x$ 和 $y$ （数据类型为uchar），首先计算其异或

$$z = x \oplus y$$

$z$ 也是一个8-bit变量， $z$ 中比特位为1的个数，即为 $x$ 和 $y$ 的汉明距离

- 为了快速得到 $z$ 中比特位为1的个数，可事先**离线**计算一个长度为 $2^8$ 的数组 $t$ ，其中第 $i$ 个数组元素值表示“十进制的正整数 $i$ 在二进制表达下的比特位为1的个数”

- 例如 $t[0]=0$ ,  
     $t[1]=1$ ,  
     $t[2]=1$ ,  
     $t[3]=2$ ,  
     $t[4]=1$ ,  
     $\dots$ ,  
     $t[255]=8$




- 因此，8-bit变量（数据类型为`uchar`） $x$ 和 $y$ 的汉明距离可通过数组 $d$ 查表得到： $d = t[x \oplus y]$ 
  - 例如  $x = 4 = (00000100)_2$ ,  
 $y = 8 = (00001000)_2$ ,  
汉明距离 $d = t[x \oplus y] = t[(00001100)_2] = t[12] = 2$
  - 例如  $x = 7 = (00000111)_2$ ,  
 $y = 3 = (00000011)_2$ ,  
汉明距离 $d = t[x \oplus y] = t[(00000100)_2] = t[4] = 1$
- 当计算高比特向量间的汉明距离时，可以将比特向量分段，每段8 bit，分段按上面方法计算汉明距离，然后累加各段的汉明距离
  - 实际实现时，每段长度可以增加至16bit，此时数组 $t$ 的长度增大为 $2^{16}$

# 哈希算法


## □ 哈希算法原理示意

- 特征提取：首先将一副图像表征为高维特征空间的一个向量
- 二值哈希：然后把图像特征向量映射为高维立方体的一个顶点
  - ✓ 是否存在最优二值哈希函数？ 未知



# 哈希算法

## □ 哈希算法过程图例





# 哈希算法(1): 局部敏感哈希

## □ 局部敏感哈希定义

- 高维空间的两点若距离很近, 则这两点映射后的哈希值相同概率较大。
- 若两点之间的距离较远, 则他们哈希值相同概率较小。

## □ 正整数向量等价变换到汉明空间

2维向量的数据集:  $A=(1,1)$     $B=(2,1)$     $C=(1,2)$     $D=(2,2)$     $E=(4,2)$     $F=(4,3)$     $\rightarrow$    坐标最大值:  $C(4)$

每个向量转换为 $n \times C$ 维哈希码:

值为 $k$ 的坐标转换为长度为 $C$ 的哈希码, 前 $k$ 位为1, 后续位为0

$A=(1,1) \rightarrow (1000, 1000) \rightarrow 10001000$

$B=(2,1) \rightarrow (1100, 1000) \rightarrow 11001000$

.....

$F=(4,3) \rightarrow (1111, 1110) \rightarrow 11111110$

# 哈希算法(1): 局部敏感哈希

## □ 一族哈希函数定义

$$h_r(p) = \begin{cases} 0, & \text{若 } p \text{ 的第 } r \text{ 位为 } 0 \\ 1, & \text{若 } p \text{ 的第 } r \text{ 位为 } 1 \end{cases}$$

## □ 选择k个哈希函数组成构成哈希表g

A=10001000		A=00
B=11001000	$g = h_2(p), h_4(p)$	B=10
C=10001100		C=00
D=11001100		D=10
E=11111100		E=11
F=11111110		F=11

table1

00	A	C
01		
10	D	B
11	E	F

## □ 查询时查找被哈希表映射在同一个桶内的点


- query  $q=(4,4) \xrightarrow{h_2(p), h_4(p)} 11111111 \xrightarrow{h_2(p), h_4(p)} 11$
- 再将q与E,F比较, 得到F是q的最近邻

# 哈希算法(1): 局部敏感哈希

□ 选择多组k个哈希函数组成构成多个哈希表g

■ 假设有如下结果。

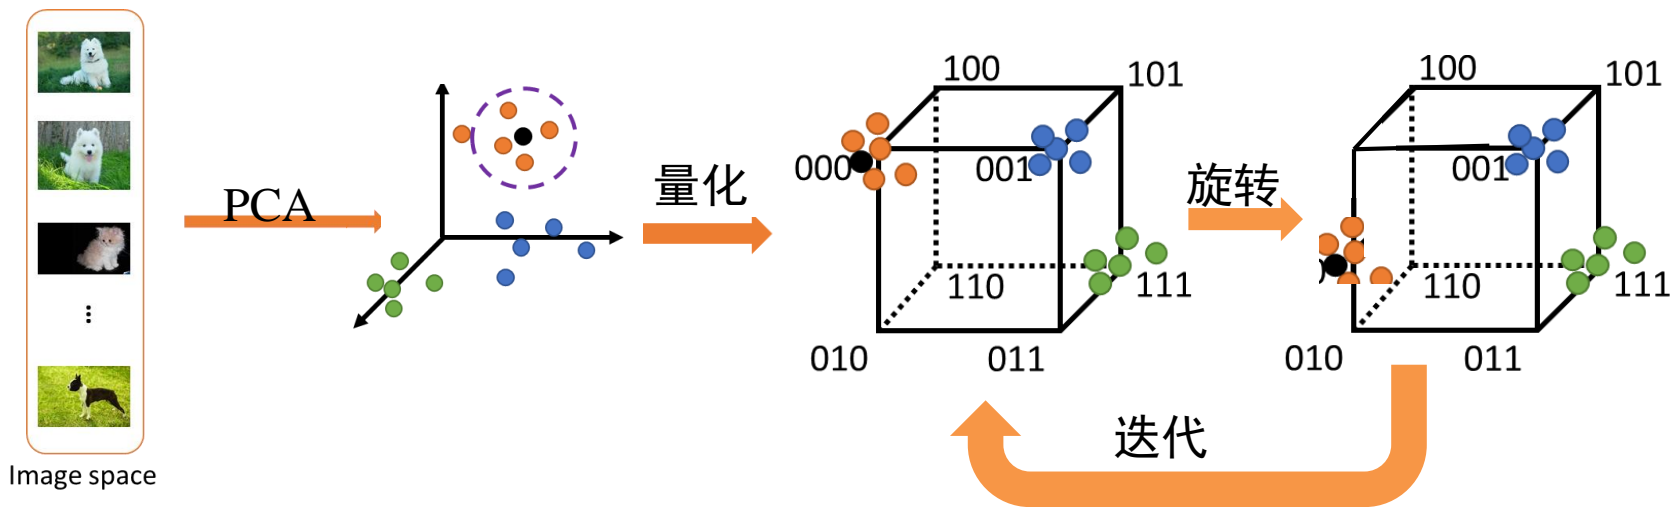

- ✓ g1分别抽取第2, 4位。
- ✓ g2分别抽取第1, 6位。
- ✓ g3分别抽取第3, 8位



# 哈希算法(2): 迭代量化 (ITQ)

## □ ITQ算法动机

- 将原始数据映射到超立方体的顶点，求解**量化误差**最小的映射
- 将超立方体在空间中**旋转**，求解旋转矩阵即能得到**最好的映射**
- 迭代这两个步骤



# 哈希算法(2): 迭代量化 (ITQ)


## □ ITQ(Iterative Quantization)算法步骤

- 对原始数据进行PCA降维

$$V = XW$$

- 最小化量化误差函数

$$Q(B, R) = \|B - VR\|_F^2$$



- ✓ 固定R更新量化结果B:  $B = \text{sgn}(VR)$
- ✓ 固定B更新旋转矩阵R
  - 计算CxC矩阵  $B^T V$  的SVD分解  $S\Omega\hat{S}^T$  然后令  $R = \hat{S}S^T$
- ✓ 迭代上述步骤，文中为50次



## □ 优点

- 没有显式的对量化过程作正交限制
- 通过学习旋转矩阵代替了对汉明空间的操作



# 哈希算法(3): 球面哈希


- 动机：用超球面，而非超平面，来分割空间
  - 特征空间更紧凑
  - 在D维特征空间定义一个封闭子空间，只需一个超球面，但需要D+1个超平面
  - 在局部敏感性方面，超球面比超平面更佳



- 选择哈希函数即构建超球面：
  - 确定球心和半径

# 哈希算法(3): 球面哈希

## □ 球哈希示意



$$h_k(x) = \begin{cases} -1 & \text{when } d(p_k, x) > t_k \\ +1 & \text{when } d(p_k, x) \leq t_k \end{cases}$$

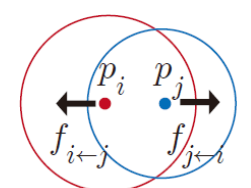
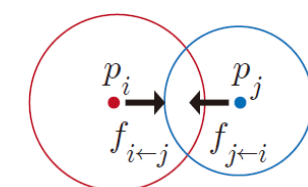
## □ 理想的超球面性质

- **平衡性**: 每个球把样本空间均分, 即球内球外各占一半
- **独立性**: 每个球的交叉部分尽量少, 即每个哈希函数相对独立
  - ✓ 任意两个球交叉区域内的样本占总样本的四分之一

$$o_i = |\{s_k | h_i(s_k) = +1, 1 \leq k \leq m\}|,$$

$$o_{i,j} = |\{s_k | h_i(s_k) = +1, h_j(s_k) = +1, 1 \leq k \leq m\}|,$$

# 哈希算法(3): 球面哈希

- 对于训练样本点集  $S = \{s_1, s_2, \dots, s_n\}$ , 迭代确定超球面
  - 1. 初始化: 从训练样本中随机选  $l$  个点作为初始球心  $p_1, p_2, \dots, p_l$ ;
  - 平衡性 ■ 2. 对各个球心, 确定半径  $t_1, t_2, \dots, t_l$ , 使得  $o_l = \frac{n}{2}$ ;
  - 3. 对每一对哈希函数, 计算  $o_{i,j}$ ;
  - 独立性 ■ 4.  $\forall i, j$ , 计算  $f_{i \leftarrow j} = \frac{1}{2} \frac{o_{i,j} - n/4}{\frac{n}{4}} (p_i - p_j)$  
  - 独立性 ■ 5.  $\forall i$ , 计算  $f_i = \frac{1}{l} \sum_{j=1}^l f_{i \leftarrow j}$ ,  $p_i = p_i + f_i$  
  - 6. 重复步骤2~5, 直至收敛, 即满足下述条件
 
$$\text{avg}(|o_{i,j} - n/4|) < \varepsilon_m \frac{m}{4} \text{ 且 } \text{std} - \text{dev}(o_{i,j}) < \varepsilon_s \frac{m}{4}$$

□ 基于球哈希定义的汉明距离计算:

$$d_{shd}(b_i, b_j) = \frac{|b_i \oplus b_j|}{|b_i \wedge b_j|}$$

其中  $\oplus$ : 异或;  $\wedge$ : 逻辑与